

RESPUESTAS A LAS CONSULTAS DEL MINISTERIO

Asistente Conversacional Inteligente — Eje 2

Fecha: Mayo 2026

Eje 1 — Costos operativos

Sobre la estimación de consumo mensual de tokens basada en el tráfico actual

Proyección a 12 meses, escenario base con curva de adopción agresiva: parte de aproximadamente USD 12 mensuales en mes 1 y crece progresivamente hasta cerca de USD 45 mensuales en mes 12, con un total acumulado anual estimado entre USD 320 y USD 400. El escenario alto-realista, contemplando que el asistente se convierta en canal natural primario del sitio, llega hasta aproximadamente USD 65 mensuales en mes 12 con acumulado anual entre USD 480 y USD 540.

El cálculo parte del tráfico verificado de mincyt.gob.ve a abril de 2026 (aproximadamente 78.000 visitas mensuales según datos públicos de SimilarWeb, con tendencia de crecimiento sostenida). Sobre esa base se proyecta un crecimiento orgánico mensual conservador del 5% en visitas, y se modela la tasa de conversión visita-a-consulta como una curva progresiva: arranca en 8% en el mes 1 cuando el ciudadano todavía no ha descubierto la herramienta, sube a 14% hacia el mes 4 en fase de consolidación, llega a 20% en el mes 7, y se estabiliza entre 22% y 25% del mes 9 en adelante, momento en el que el asistente se establece como canal de consulta. Esa curva refleja el patrón documentado de adopción de IA en sitios institucionales: una vez que el usuario comprueba que la herramienta le funciona, la usa cada vez más. Para el escenario alto se trabaja con conversión llegando al 30% en mes 12 y crecimiento de visitas del 8% mensual. Cada conversación promedia 9.000 tokens de entrada y 1.250 de salida sobre 2.5 turnos de diálogo, considerando system prompt, contexto RAG recuperado, historial conversacional y respuesta. Con el modelo elegido (Llama 4 Scout en DeepInfra) cada conversación cuesta aproximadamente USD 0.0011, lo que da los rangos mensuales y anuales descritos. La proyección está deliberadamente holgada para que el Ministerio tenga costos predecibles incluso en escenarios de adopción mayor a la esperada.

Sobre el costo por cada 1.000 tokens en el modelo elegido

El modelo elegido es Llama 4 Scout, con costo verificado de USD 0.00008 por 1.000 tokens de entrada y USD 0.00030 por 1.000 tokens de salida en DeepInfra al 7 de mayo de 2026. El proveedor de pago efectivo es OpenRouter, que rutea al backend de DeepInfra al mismo precio

base y resuelve el problema de método de pago desde Venezuela aceptando criptomonedas (USDT) explícitamente.

Llama 4 Scout es un modelo Mixture-of-Experts con 109.000 millones de parámetros totales y 17.000 millones activos por consulta, ventana de contexto de 10 millones de tokens (la más amplia de la industria, particularmente útil para RAG porque permite incluir contexto institucional extenso sin chunking agresivo), capacidad multimodal nativa de texto e imagen, y soporte oficial para español confirmado por Meta. Como modelo de respaldo en caso de cualquier problema de disponibilidad, queda configurado Qwen 2.5 72B Instruct (USD 0.36 IN / USD 0.40 OUT por millón de tokens en DeepInfra), de muy buen rendimiento en español. Para escalar a respuestas de máxima complejidad podría invocarse selectivamente Llama 4 Maverick (USD 0.15 IN / USD 0.60 OUT, modelo de 400.000 millones de parámetros con 128 expertos), pero esa optimización queda como evolución posterior, no parte del entregable inicial. La verificación de precios se hizo contra las páginas oficiales de DeepInfra y OpenRouter el 7 de mayo de 2026 y queda documentada para auditoría.

Sobre el techo o límite de gasto mensual y por qué el control no puede ser "que se caiga el sitio"

El asistente nunca se cae por motivos económicos: la arquitectura de control de gasto opera en cuatro capas progresivas y el corte físico solo existe como última línea de defensa contra ataque o anomalía, no como mecanismo de operación normal. El escenario que el Ministerio quiere evitar — que amanezca con el asistente caído porque "se acabó el saldo" — es exactamente lo que esta arquitectura está diseñada para prevenir.

La primera capa es **predictiva, no reactiva**: caché semántico que reduce entre 30% y 40% del consumo real al servir respuestas a preguntas frecuentes desde memoria, sin invocar al modelo. En un sitio gubernamental donde un alto porcentaje de las consultas se concentra en becas, convocatorias, programas y trámites recurrentes, esta capa no es marginal — es estructural. La segunda capa es **rate limiting inteligente** por IP, sesión y patrón de uso: 10 consultas por minuto y 50 diarias por usuario individual, con CAPTCHA invisible ante patrones anómalos, lo que mata cualquier intento de abuso o scraping antes de que mueva la aguja del consumo. La tercera capa es **auto-recarga programada con tope mensual configurable**: el Ministerio define un tope de gasto mensual (sugerido USD 100 inicial, ampliable según evolucione el uso real, configurable desde panel sin redeploy) y el sistema ejecuta auto-recarga del saldo cuando baja del umbral mínimo configurado, hasta agotar el cupo mensual aprobado, todo con alertas tempranas a los responsables del Ministerio cuando el consumo alcanza el 60%, 80% y 95% del techo mensual. La cuarta capa es **modo de degradación controlada antes del corte**: si el consumo se acerca al tope mensual, el sistema entra automáticamente en modo restringido donde solo sirve respuestas cacheadas y muestra al usuario un mensaje cordial del estilo "estamos atendiendo alta demanda, tu consulta puede demorar unos minutos", manteniendo el servicio operativo aún ante consumo anómalo. Solo si todas las capas anteriores fallan simultáneamente — escenario de ataque masivo coordinado, o decisión administrativa explícita del Ministerio de no ampliar el cupo — el sistema entra en última línea de defensa con saldo agotado, momento en el que ya hay alertas activas hace horas y la situación está siendo gestionada activamente. En operación normal el Ministerio nunca ve un corte:

ve un dashboard ejecutivo en tiempo real con consumo acumulado, proyección de cierre de mes y alertas tempranas mucho antes de que cualquier umbral se acerque.

Sobre el costo promedio estimado por iteración

Una iteración o turno de conversación cuesta aproximadamente USD 0.00044 con Llama 4 Scout, y una conversación completa de 2.5 turnos promedio cuesta cerca de USD 0.0011.

El cálculo es directo: 3.600 tokens de entrada por turno multiplicados por USD 0.08 por millón da USD 0.000288, y 500 tokens de salida por turno multiplicados por USD 0.30 por millón da USD 0.00015, lo que totaliza USD 0.000438 por turno o USD 0.00109 por conversación de 2.5 turnos. Esta cifra es la base sobre la que se construyen las proyecciones mensuales, y permite al Ministerio modelar internamente cualquier escenario de tráfico simplemente multiplicando por la cantidad de conversaciones esperadas. La cifra es conservadora porque asume que cada conversación consume lo que consume el promedio observado en sistemas RAG comparables; el caché semántico que opera en producción reduce el costo efectivo entre 30% y 40% adicional una vez que el sistema acumula patrones de uso, pero ese ahorro queda fuera de la proyección como margen de seguridad.

Sobre la lista detallada de proveedores y costos para el día 0+1 de operación

La arquitectura corre íntegramente en infraestructura del Ministerio o de su ecosistema institucional (CNTI/Cenditel) con un único proveedor externo: la API de inferencia LLM contratada vía OpenRouter con saldo en USDT. No hay dependencia de "tiers gratuitos" de servicios comerciales — un Ministerio no opera sobre planes de marketing que pueden cambiar mañana.

La infraestructura del backend, el motor RAG, la base de datos vectorial Qdrant, el servicio de embeddings BGE-M3, el sistema de logs, monitoreo, backups y todo el stack operativo corre en un servidor aportado por el Ministerio con la especificación cotizada (4-8 vCPU, 16-32 GB RAM, 100 GB SSD, sin GPU). Esta es la primera opción y la recomendación fuerte por tres razones: técnicamente, mantener los datos institucionales y el corpus indexado dentro del territorio nacional cumple con el principio de Privacidad y la línea de soberanía declarada en el Código de Ética; operativamente, elimina costos cloud recurrentes; políticamente, encarna el principio de Ciencia Abierta y soberanía tecnológica. Como segunda opción documentada para casos donde la infraestructura del Ministerio no esté disponible al momento del go-live, queda contemplado un servidor en Hetzner Cloud (VPS CCX23 con 4 vCPU, 16 GB RAM, 160 GB SSD) por aproximadamente USD 27 mensuales, accesible desde Venezuela y con métodos de pago que incluyen criptomonedas. El widget se sirve bajo subdominio del Ministerio (asistente.mincyt.gob.ve o similar), aprovechando el dominio y certificado SSL ya existentes. Los servicios de email transaccional para alertas operativas se canalizan por SMTP del Ministerio o por la cuenta institucional ya disponible. El monitoreo es Grafana, Prometheus y Loki auto-hospedados en el mismo servidor del backend, sin dependencia de servicios externos. Los backups se replican a almacenamiento institucional (Cenditel u otro) o a un secondary del propio servidor.

Hay un único punto que requiere infraestructura fuera de Venezuela: el egress hacia la API de inferencia LLM, porque los proveedores estadounidenses tienen geo-IP blocking activo sobre

Venezuela bajo políticas OFAC. Para resolverlo de forma profesional, el sistema rutea las llamadas a la API a través de un proxy egress mínimo en Hetzner Brasil o Panamá (instancia de USD 5 a USD 7 mensuales), que actúa solo como puente saliente y no almacena ningún dato. Este proxy es transparente, está documentado y controlado, y resuelve el único punto de fricción geopolítica del proyecto. El costo operativo total mensual del escenario base, contemplando inferencia, proxy egress y todo lo demás corriendo en infraestructura del Ministerio, se ubica entre USD 12 (mes 1) y USD 45 (mes 12 al pico de adopción), con acumulado anual estimado entre USD 320 y USD 540 según escenario. La cuenta del proveedor de inferencia se contrata directamente entre el Ministerio y OpenRouter, con saldo cargado en USDT por el Ministerio, sin intermediación, sin lock-in y sin costos cruzados.

Eje 2 — Infraestructura

Sobre la garantía por escrito de que la solución no demandará recursos adicionales

La especificación cotizada (4-8 vCPU, 16-32 GB RAM, 100 GB SSD, sin GPU) es técnicamente suficiente para la operación del asistente bajo Condiciones de Capacidad Garantizada explícitas, y se garantiza por escrito que cualquier upgrade necesario dentro de esas condiciones se entrega sin costo adicional. La cláusula opera como compromiso ejecutable, no como declaración de buenas intenciones.

La validación técnica se hizo contra la fórmula oficial de consumo de memoria publicada por Qdrant. Para un corpus de hasta 50.000 páginas indexadas equivalentes a aproximadamente 500.000 fragmentos vectorizados con embeddings de hasta 1.024 dimensiones, el consumo proyectado de RAM oscila entre 80 MB y 1 GB cuando se opera con almacenamiento mapeado en disco y quantización escalar int8, ambas técnicas estándar de producción. El consumo de disco proyectado para el escenario más exigente totaliza aproximadamente 33 GB, lo que deja holgura cómoda sobre los 100 GB cotizados. El backend FastAPI con cuatro workers consume aproximadamente entre 1 y 1.6 GB de RAM en estado estable porque la inferencia LLM se ejecuta vía API externa, no en este servidor. Bajo carga de hasta 500 sesiones de usuario concurrentes en ventana de 15 minutos (equivalente a aproximadamente 15 requests por segundo sostenidos), la especificación es suficiente con margen.

La cláusula de garantía tiene la siguiente forma operativa: se garantiza que la especificación es técnicamente suficiente bajo cinco Condiciones de Capacidad Garantizada explícitas. Primero, corpus indexado de hasta 50.000 páginas equivalentes materializadas en hasta 500.000 fragmentos vectorizados. Segundo, modelos de embedding de dimensión menor o igual a 1.024. Tercero, carga concurrente de hasta 500 sesiones en ventana de 15 minutos. Cuarto, inferencia LLM mediante API externa y no inferencia local en el servidor. Quinto, configuración de Qdrant con almacenamiento mapeado en disco y quantización habilitada cuando aplique. Si durante los 30 días posteriores a la puesta en producción se demuestra técnicamente, mediante métricas observables (utilización sostenida de CPU superior al 80% por más de 15 minutos, RAM superior al 90%, o latencia p95 por encima del SLA acordado), que la especificación es insuficiente dentro de las Condiciones, se

realiza el ajuste necesario sin costo, sea por optimización de configuración, sea por upgrade de la instancia hasta el techo superior del rango cotizado (8 vCPU, 32 GB de RAM, 100 GB SSD), sin cargo adicional para el Ministerio. Quedan expresamente excluidos los escenarios que excedan las Condiciones, en particular crecimiento del corpus por encima de 50.000 páginas, embeddings de dimensión superior a 1.024, requerimientos de inferencia local con GPU, funcionalidades nuevas no contempladas (multimodalidad pesada con video o audio crudo, agentes con herramientas externas, búsqueda sobre archivos binarios), y picos de tráfico sostenido mayores a 500 sesiones concurrentes. Estos casos se cotizan como evolución del proyecto bajo acuerdo separado, garantizando al Ministerio que no hay sorpresas dentro del alcance acordado y dejando claro qué cosas sí abrirían conversación.

Sobre el mantenimiento de Qdrant y la actualización del corpus

Qdrant es operacionalmente liviano y la solución cotizada le quita al Ministerio una carga operativa que en otro contexto demandaría personal especializado. La mayoría de tareas operativas se automatizan o son ejecutadas nativamente por el motor sin intervención humana, y las pocas que requieren acción manual quedan documentadas y operables por personal del Ministerio tras la capacitación incluida.

Las tareas automáticas que operan sin intervención son: backups diarios mediante snapshots con retención de 14 días, monitoreo continuo de uso de CPU, RAM, disco y latencia con alertas a los contactos designados del Ministerio, rotación de logs, renovación automática de certificados TLS, optimización interna del índice (rebuild HNSW y compactación de segmentos que Qdrant ejecuta nativamente), y aplicación de parches de seguridad del sistema operativo configurados como tarea automática. Las tareas operables por el Ministerio tras la capacitación de cuatro horas son: ingesta de contenido nuevo cuando el Ministerio publica programas, becas, convocatorias o documentos institucionales (mediante un script de línea de comando documentado que toma una carpeta con archivos, los procesa, chunkea, embebe e indexa), upgrade de versión menor de Qdrant (reemplazo de imagen Docker con reinicio supervisado, paso a paso documentado en runbook), restauración desde snapshot ante incidente menor, y verificación de estado del sistema. Las tareas que sí demandan criterio experto son episódicas: upgrades de versión mayor de Qdrant (con frecuencia anual o superior), tuning fino de parámetros HNSW solo si las métricas degradan, y re-indexaciones totales por cambio de embedder. Estas se cubren mediante un retainer mensual de soporte técnico extendido cotizable como evolución, opcional para el Ministerio. Como evolución también queda disponible, cotizable separadamente, un panel administrativo web para gestión del corpus por personal no-técnico (estimado en 30 a 50 horas adicionales) y la sincronización automática mediante webhook desde el CMS del Ministerio para que el corpus se actualice sin intervención humana cuando se publica contenido nuevo (estimado en 60 a 100 horas adicionales según el CMS).

Durante los 30 días corridos posteriores a la puesta en producción, se garantiza respuesta a incidentes críticos (servicio caído o sin respuesta a queries) en máximo 4 horas hábiles desde la notificación con resolución dirigida a restaurar el servicio en menos de 24 horas hábiles, respuesta a incidentes mayores (degradación funcional, respuestas incorrectas sistemáticas, errores de ingesta) en máximo un día hábil con plan de mitigación dentro de las 72 horas, respuesta a consultas

operativas y dudas del equipo en máximo dos días hábiles, corrección sin cargo de cualquier defecto atribuible al desarrollo entregado, y disponibilidad objetivo del servicio del 99% medida sobre la ventana de 30 días. El handover técnico final al cierre incluye documentación operativa entregada, runbook de incidentes comunes y sesión de cierre de una hora para resolver dudas finales. Vencidos los 30 días, las tareas automatizadas continúan operando autónomamente sin requerir intervención adicional.

Eje 3 — Calidad del entregable

Sobre el porcentaje de precisión garantizado y el SLA de corrección

No se garantiza un porcentaje único y absoluto de precisión global, sino métricas medibles según metodología RAGAS sobre un Conjunto de Casos de Prueba acordado con el Ministerio, con SLA de corrección por severidad durante los 30 días post go-live. Comprometer cifras absolutas como "99% de precisión" en un sistema generativo sería técnicamente irresponsable, pero comprometer métricas medibles, auditables y reproducibles es estándar profesional.

Los umbrales propuestos son alcanzables dentro del alcance del proyecto y se calibraron para ser exigentes pero realistas. **Faithfulness**, que mide la fracción de afirmaciones de la respuesta que están sustentadas por el contexto recuperado, mayor o igual a 0.85 (rango enterprise típico va de 0.88 a 0.94, así que 0.85 deja margen razonable). **Context Recall**, que mide qué fracción de la información relevante del corpus fue efectivamente recuperada, mayor o igual a 0.85. **Answer Relevance**, que mide pertinencia de la respuesta respecto a la pregunta, mayor o igual a 0.85. Y un cuarto umbral particularmente importante: **cero alucinaciones graves** sobre el subconjunto crítico del Conjunto de Casos de Prueba, entendiendo por alucinación grave cualquier información fácticamente incorrecta sobre programas, becas, convocatorias, requisitos formales o trámites del Ministerio. El asistente implementa además una política de "preferir el silencio honesto antes que inventar": cuando la confianza interna del sistema está por debajo del umbral configurado, el asistente responde derivando al canal humano de atención del Ministerio en lugar de generar respuesta especulativa. Este principio operativo está alineado con el principio de Rendición de Cuentas del Código de Ética y se documenta en el reporte de adherencia.

El SLA de corrección por severidad opera durante los 30 días posteriores a la puesta en producción, con tiempos contados en horas o días hábiles desde la notificación formal por la contraparte designada del Ministerio. **Severidad crítica**, definida como información incorrecta sobre trámite vigente, convocatoria abierta, requisitos formales o cualquier información que pueda inducir a error material al ciudadano: corrección en 24 horas hábiles. **Severidad alta**, definida como información desactualizada o parcialmente errónea sobre programas activos: corrección en 72 horas hábiles. **Severidad media**, definida como errores de redacción, tono o claridad sin afectar la corrección sustantiva: corrección en 5 días hábiles. **Severidad baja**, definida como mejoras de estilo o pulido de la respuesta: corrección en la próxima ventana de mantenimiento. Toda corrección queda

documentada con trazabilidad de causa raíz y prueba de regresión sobre el Conjunto de Casos de Prueba para asegurar que la corrección no introduce regresiones en otras categorías.

Sobre la cantidad de casos de prueba, quién participa del Ministerio y quién certifica

El protocolo de QA opera sobre un Conjunto de Casos de Prueba de 700 casos en ocho categorías, con una Mesa de Certificación Institucional reducida de tres referentes del Ministerio centrada en alcance de auditoría y no en horas de trabajo, y el sistema de evaluación se entrega como instrumento de certificación temporal que se desmonta al cierre del go-live. El Ministerio no hereda una herramienta más para administrar; lo que hereda es la evidencia firmada de que el asistente cumple antes de salir a producción.

El Conjunto de Casos de Prueba se distribuye como sigue: 150 casos sobre programas y políticas activas del Ministerio como núcleo del corpus institucional, 120 casos sobre becas y convocatorias vigentes por su criticidad temporal, 100 casos sobre trámites y requisitos formales por el riesgo de inducir error material, 80 casos sobre el ecosistema aliado de 27 entidades, 70 casos límite y ambigüedades para probar robustez, 70 casos de manejo correcto de "no sé" o "fuera de alcance" para verificar la política antialucinación, 60 casos sobre registro adaptado a perfil de usuario validando que el asistente diferencia tono entre estudiante, investigador, gestor y ciudadano general, y 50 casos adversariales que prueban resistencia a prompt injection, manipulación, sesgo y lenguaje ofensivo. **El diseño y construcción del Conjunto, el harness de evaluación con métricas RAGAS, la ejecución de las corridas de evaluación y la generación del dashboard de validación corren íntegramente sin carga operativa para el Ministerio.**

La Mesa de Certificación Institucional designada por el Ministerio se compone de **tres referentes** con autoridad para validar la salida a producción. Un **referente de contenidos institucionales** del Ministerio, encargado de auditar la exactitud sustantiva de las respuestas del asistente sobre programas, becas, convocatorias y trámites, validando que ningún contenido contradice la posición oficial del Ministerio. Un **referente técnico** designado por el Despacho del Viceministerio para el Desarrollo de las TIC o la Oficina de Tecnologías de Información, encargado de auditar la arquitectura, las métricas, los logs de retrieval y el cumplimiento de la especificación técnica. Un **referente designado por la Dirección General de Desarrollo y Aplicación de Inteligencia Artificial (DGDAIA)** o equivalente, encargado de auditar la adherencia operativa del asistente al Código de Ética para el Desarrollo y Aplicación Responsable de la Inteligencia Artificial publicado por el propio Ministerio. La aprobación formal para el pase a producción requiere el cumplimiento simultáneo de cuatro criterios: faithfulness mayor o igual a 0.85 sobre el Conjunto, cero alucinaciones graves sobre las categorías de programas, becas y trámites, al menos 95% de respuestas correctas en la categoría de "no sé" o "fuera de alcance", y acta formal de certificación firmada por la Mesa. Sin los cuatro no hay go-live, y la remediación necesaria queda sin costo adicional para el Ministerio.

El sistema de evaluación que produce las métricas (Conjunto de Casos de Prueba, harness de RAGAS, scripts de corrida, dashboard de validación) opera como **instrumento de certificación temporal**: se construye, se usa para certificar el go-live, se entrega como evidencia firmada al Ministerio (en formato de reporte y dataset), y **se desmonta al cierre del proyecto**. El Ministerio no hereda una infraestructura permanente de evaluación que tenga que mantener, debuggear o

actualizar. Si en el futuro decide implementar evaluación continua del asistente como práctica recurrente, esto queda como evolución cotizable bajo acuerdo separado, en cuyo caso la herramienta puede reactivarse y operarse periódicamente.

Sobre la naturaleza del reporte de adherencia al Código de Ética y qué líneas se siguen

El Código de Ética para el Desarrollo y Aplicación Responsable de la Inteligencia Artificial publicado por el Ministerio no es un documento que se consulte al final del proyecto: es normativa de producción desde el día cero del desarrollo, citada literalmente y mapeada a cada componente de la solución técnica. Existe disposición explícita a someterse a auditoría externa por parte del auditor que el Ministerio designe, bajo la propia normativa del Código. Esto cambia el carácter del reporte de "documento entregable" a "manifestación documentada de un cumplimiento que estuvo embebido en cada decisión técnica desde el primer día".

El Código fue elaborado por la Dirección General de Desarrollo y Aplicación de Inteligencia Artificial (DGDAIA), adscrita al Despacho del Viceministerio para el Desarrollo de las Tecnologías de la Información y Comunicación (DVDTIC) del Ministerio del Poder Popular para Ciencia y Tecnología. Su versión vigente fue la propuesta original elaborada por el Centro Nacional de Desarrollo e Investigación en Telecomunicaciones (CENDIT) en 2024, y formaliza nueve principios éticos fundamentales que guían el desarrollo y la aplicación responsable de la IA en Venezuela. Cada principio se cita textualmente en la documentación del proyecto y se mapea a evidencia técnica concreta en el asistente.

El principio de **Inteligencia Artificial Humanista** se manifiesta en que el asistente respeta la autonomía del ciudadano sin imponerle perfiles ni categorías, opera como herramienta que amplía las capacidades humanas y no como sustituto de la decisión informada, y deriva al canal de atención humano del Ministerio cuando una consulta excede su alcance o requiere atención sensible. La evidencia documentada incluye el system prompt completo del asistente, las reglas de derivación al canal humano, y la política antialucinación. El principio de **Equidad, Igualdad y No Discriminación** se manifiesta en el subconjunto del Conjunto de Casos de Prueba que valida queries de subgrupos diversos (mujeres, jóvenes, comunidades originarias, personas con discapacidad, lenguaje coloquial), en el registro adaptativo del asistente que respeta diversidad de perfiles, y en la ausencia deliberada de mecanismos de segmentación o categorización de usuarios. La evidencia incluye el reporte de equidad sobre subconjuntos del Conjunto de Casos de Prueba. El principio de **Responsabilidad Ambiental** se manifiesta en la elección deliberada de un modelo cuantizado (Llama 4 Scout en FP8) que reduce significativamente el consumo energético frente a alternativas más pesadas, en la operación sin GPU del backend, y en el caché semántico que evita inferencias innecesarias. La evidencia incluye una ficha de footprint estimado del asistente. El principio de **Seguridad** se manifiesta en hardening del endpoint, controles contra prompt injection validados por el subconjunto adversarial del Conjunto, cifrado de datos en tránsito y reposo, anonimización de logs, y plan documentado de gestión de incidentes que cubre los tres niveles del Código (datos, modelo, infraestructura). El principio de **Privacidad** se manifiesta en minimización de datos por diseño, ausencia de almacenamiento de información personal identificable más allá de lo estrictamente necesario, mecanismo procedimental documentado para los derechos de acceso,

rectificación, cancelación y oposición, y aviso de privacidad visible al usuario antes de iniciar interacción.

El principio de **Transparencia** es el que más profundamente está embebido en la arquitectura: el asistente cita la fuente institucional de cada respuesta sustantiva con enlace al documento oficial del Ministerio o al programa correspondiente, los logs de retrieval son auditables y permiten reconstruir por qué el asistente respondió lo que respondió ante cualquier consulta específica, y existe un canal de contraloría social materializado en un botón de "reportar respuesta incorrecta" disponible al ciudadano final, cuyo feedback se integra al ciclo de mejora del asistente. La evidencia incluye el diseño de citados de fuentes, el esquema de logs auditable y el flujo del mecanismo de contraloría. El principio de **Rendición de Cuentas** se manifiesta en el SLA de corrección por severidad, en la trazabilidad documentada de cada respuesta, en la supervisión humana siempre activa sobre el sistema, y en la cláusula explícita de que el asistente no sustituye decisiones formales del Ministerio. La evidencia incluye el SLA, los términos de uso del asistente, y el disclaimer institucional visible en cada respuesta. El principio de **Ciencia Abierta** es el que más directamente alinea el stack técnico cotizado con el Código: el asistente se construye íntegramente sobre código abierto y software libre — Llama 4 Scout es open-source, Qdrant es open-source, FastAPI es open-source, BGE-M3 es open-source, todo el código del asistente es entregado al Ministerio bajo licencia que permite su revisión, modificación y mejora. La elección del stack no fue preferencia, fue cumplimiento literal del principio que el Código describe textualmente como: *"el código abierto y el software libre son pilares esenciales para garantizar la transparencia, la accesibilidad y la colaboración en el desarrollo de la inteligencia artificial"*. El principio de **Excelencia** se manifiesta en la articulación con el ecosistema institucional venezolano (Cenditel, CENDIT, universidades nacionales como UCV, USB, ULA), en la transferencia de conocimiento al equipo del Ministerio mediante la capacitación incluida y la documentación técnica abierta, y en el compromiso con benchmarks medibles y reproducibles que permiten evaluación crítica del trabajo entregado.

Sobre la naturaleza formal del reporte: el Reporte de Adherencia al Código de Ética que se entrega al cierre del proyecto es un autoinforme estructurado con evidencia documental trazable principio por principio. Existe **disposición explícita a someterse a auditoría externa** por parte del tercero independiente que el Ministerio designe. Los candidatos naturales son CENDIT (que elaboró la propuesta original del Código en 2024 y por lo tanto conoce su espíritu), Cenditel como centro nacional de desarrollo en tecnologías libres, una universidad nacional, o un auditor privado especializado. Se facilita todo el material técnico, la evidencia documental y el código fuente necesarios para que esa auditoría externa se ejecute, sin costo de coordinación adicional para el Ministerio. La auditoría externa opera bajo la propia normativa del Código de Ética del Mincyt como marco evaluativo, cerrando un círculo institucional coherente: el código nació en CENDIT, rige el desarrollo desde el día cero, y puede auditarse por quien el Ministerio designe bajo su propia normativa. Los honorarios del auditor externo no están incluidos en el presupuesto base y se cotizan por separado bajo acuerdo directo entre el Ministerio y el auditor elegido.